# UNIVERZITET U SARAJEVU

# FAKULTET ZA SAOBRAĆAJ I KOMUNIKACIJE

**PROJEKTNI RAD IZ PREDMETA:**

Digitalna obrada signala

| | |
|---|---|
| **Tema rada:** | Digitalizacija govornog signala (praktična primjena spektrogramske analize govora) |

| | |
|---|---|
| **Predmetni nastavnik:** | Doc. dr Adisa Hasković Džubur |
| **Student:** | Jusuf Dacić |
| Broj indeksa: | 8726 |
| Usmjerenje: | Kompjuterske i informacijske tehnologije |
| Godina studija: | II godina, I ciklus |
| **Rezultat rada:** | |

*Sarajevo, juni 2025.*

# SADRŽAJ

**UVOD** ..... 2

**1. PREGLED ISTRAŽIVANJA IZ OBLASTI DIGITALNE OBRADE GOVORA** ..... 3

**2. TEORIJSKE OSNOVE** ..... 5

*2.1. Analiza govora* ..... 5

*2.2. Govor kao analogni signal i A/D konverzija* ..... 6

*2.3. Nyquistov teorem* ..... 7

*2.4. Obrada digitalnog oblika signala, frekvencije i formanti* ..... 8

*2.5. Fourijerova transformacija i spektrogram* ..... 9

*2.6. D/A konverzija* ..... 11

**3. PREGLED I ANALIZA ALATA** ..... 13

**4. DIGITALIZACIJA GOVORNOG SIGNALA I PRAKTIČNA PRIMJENA SPEKTROGRAMSKE ANALIZE GOVORA** ..... 15

*4.1. Analiza govora izgovorenog normalnim tonom* ..... 16

*4.2. Analiza govora izgovorenog šapatom* ..... 21

*4.3. Analiza govora izgovorenog visokim tonom* ..... 24

*4.5. Analiza spektrograma iste rečenice izgovorena brzo i sporo normalnim tonom, nakon filtriranja.* ..... 28

*4.6. Rekonstrukcija digitalnog signala u analogni oblik* ..... 29

**5. PRIMJENA DIGITALNE OBRADE GOVORA DANAS** ..... 31

**ZAKLJUČAK** ..... 33

**LITERATURA** ..... 34

**POPIS SLIKA** ..... 35

**POPIS TABELA** ..... 36

# UVOD

U današnjem digitalnom dobu, glas i govor predstavljaju neizostavan vid međuljudske komunikacije, a njihova obrada putem savremenih tehnologija zauzima ključno mjesto u razvoju brojnih sistema. Govor je po prirodi analogni signal, neprekidan u vremenu i vrijednosti i kao takav nije direktno pogodan za obradu u digitalnim uređajima poput računara ili mobilnih telefona. Upravo zato se koristi proces digitalne obrade govora, kojim se analogni signal pretvara u digitalni oblik, odnosno niz diskretnih vrijednosti koje se mogu čuvati, analizirati i dalje obrađivati.

Ovaj proces započinje analogno – digitalnom konverzijom, čime se govor digitalizuje i priprema za daljnju obradu. Jedan od ključnih aspekata takve obrade jeste mogućnost analize frekvencijskih karakteristika signala, za što se često koristi spektrogram, koji omogućava vizuelni prikaz kako se različite frekvencije u signalu mijenjaju kroz vrijeme. Time se omogućava detaljna analiza govora u različitim uslovima. Spektrogramska analiza igra važnu ulogu ne samo u inženjerskom i naučnom kontekstu, već i u logopediji, fonetici, medicinskoj dijagnostici i mnogim drugim oblastima.

Ovaj rad ima za cilj pružiti cjelovitu sliku o tome kako funkcioniše digitalna obrada govora, sa fokusom na spektrogramsku analizu. Poseban akcenat stavljen je na primjenu različitih softverskih alata, među kojima je u ovom radu izabran MATLAB zbog svojih preciznih matematičkih mogućnosti i fleksibilnosti u prikazu i analizi podataka.

# 1. PREGLED ISTRAŽIVANJA IZ OBLASTI DIGITALNE OBRADE GOVORA

Tabela 1. Kratak pregeld rada pod nazivom “Primjena PRAAT programa u logopediji”

| **Primjena PRAAT programa u logopediji [1]** | | | | |
|---|---|---|---|---|
| **Ključne ideje** | **Metodologija** | **Alati** | **Doprinos** | **Nedostaci** |
| Primjena akustičke analize za procjenu kvaliteta glasa pomoću spektrograma i AVQI skriptu. | Korištena je spektrogramska analiza, analiza formanata, jittera, shimmera, FFT i LPC[1] spektar. Poseban fokus na AVQI skriptu za dijagnostičku primjenu. | PRAAT (besplatan softver), AVQI[2] skripta. | Omogućava logopedima i studentima vizualizaciju i dijagnozu poremećaja glasa kroz akustičku obradu jednog tona. | Nije analiziran sadržaj različitih vokalnih modaliteta, što bi omogućilo precizniju spektrogramsku analizu različitih modaliteta |

Tabela 2. Kratak pregeld rada pod nazivom “Primjena formantske analize u konstrastivnoj akustici hrvatskog i srpskog jezika”

| **Primjena formantske analize u kontrastivnoj akustici hrvatskog i srpskog jezika [2]** | | | | |
|---|---|---|---|---|
| **Ključne ideje** | **Metodologija** | **Alati** | **Doprinos** | **Nedostaci** |
| Analiza akustičkih razlika između hrvatskog i srpskog jezika uz mjerenje formantskih frekvencija i F0. | Snimanje 162 govornika oba jezika u kontrolisanim uvjetima, analiza formantskih frekvencija (F1–F3) i temeljne frekvencije (F0), obrada u MATLAB-u i JASP-u. | MATLAB, JASP, profesionalna oprema za snimanje govora (AKG, Marantz, ZOOM). | Pruža detaljan fonetski uvid u razlike među jezicima i spolovima, postavlja standarde za rad s velikim korpusima govora. | Rad je orijentisan na brojčane analize bez spektrogramske usporedbe i bez prikaza vokalnih varijacija istog govora. |

[1] Linear Predictive Coding, metoda za analizu spektra govora pomoću predikcije prethodnih uzoraka.
[2] Acoustic Voice Quality Index, alat za kvantitativnu procjenu kvalitete glasa.

Tabela 3. Kratak pregled rada pod nazivom “Optimizing Vowel Formant Measurements in Four Acoustic Analysis Systems for Diverse Speaker Groups”

| **Optimizing Vowel Formant Measurements in Four Acoustic Analysis Systems for Diverse Speaker Groups [3]** | | | | |
|---|---|---|---|---|
| **Ključne ideje** | **Metodologija** | **Alati** | **Doprinos** | **Nedostaci** |
| Mjerenje formanta samoglasnika u četiri akustička analitička sustava za različite skupine govornika. | Analiza vokala pomoću CSL, Praat, TF32 i WaveSurfer softvera, snimanje riječi od strane više govornika. | CSL, Praat, TF32, WaveSurfer. | Pokazuje kako softver utiče na fomantsku analizu kod različitih govornika. | Fokusiran na optimizaciju parametara, bez spektrogramske vizualizacije, |

Tabela 4. Kratak pregled rada pod nazivom “Comparison of Praat and Computerized Speech Lab for Formant Analysis in Maxillectomy Patient”

| **Comparison of Praat and Computerized Speech Lab for Formant Analysis in Maxillectomy Patients [4]** | | | | |
|---|---|---|---|---|
| **Ključne ideje** | **Metodologija** | **Alati** | **Doprinos** | **Nedostaci** |
| Tačnost formantske analize različitih softvera kod osoba nakon hiruškog uklanjanja viliice. | Snimanje vokala pacijenata, analiza formanta pomoću Praat i CSL, statističko poređenje rezultata. | Praat, CSL. | Potvrđuje visoku korelaciju između dva softvera i važnost pravilnih podešavanja. | Fokus na kliničku primjenu bez prikaza spektrograma ili varijacija u govoru. |

Tabela 5. Kratak pregled rada pod nazivom “Acoustic Analysis of Vowel Formant Frequencies in Genetically-Related and Non-Genetically Related Speakers”

| **Acoustic Analysis of Vowel Formant Frequencies in Genetically-Related and Non-Genetically Related Speakers [5]** | | | | |
|---|---|---|---|---|
| **Ključne ideje** | **Metodologija** | **Alati** | **Doprinos** | **Nedostaci** |
| Na koji način razlikujemo govornike pomoću formantskih frekvencija vokala. | Snimanje spontanog govora, ručno označavanje dijelova signala koji su relevantni za obradu, ekstrakcija (mjerenje vrijednosti) F1–F4 u Praat-u. | Praat. | Pokazuje da formantske frekvencije (F3 i F4) pomažu u razlikovanju govornika, uključujući blizance. | Fokus na forenzičku primjenu (u sudstvu, kriminalistici i identifikaciji osoba putem govora), bez spektrogramske analize i poređenja modaliteta. |

# 2. TEORIJSKE OSNOVE

## *2.1. Analiza govora*

Prema Horgi i Likeru (2016) govor možemo analizirati s triju glavnih stajališta: sa stajališta proizvodnje, prijenosa i primanja govora, a istraživačke metode kojima se nastoji opisati neki aspekt govora, najčešće se dijele na akustičke, artikulacijske i perceptivne. Artikulacijske metode bave se fiziološkim i biomehaničkim aspektima proizvodnje govora, te uključuju snimanje pokreta govornih organa (npr. jezika, usana, nepca) pomoću tehnika poput elektromiografije ili ultrazvuka. Perceptivne metode oslanjaju se na subjektivno slušno ocjenjivanje govor se analizira na osnovu dojma koji ostavlja na slušaoce, što se često koristi u logopedskoj dijagnostici S druge strane, akustičke metode analiziraju govor kao zvučni signal. U savremenim pristupima, one često uključuju digitalno bilježenje i numeričku obradu karakteristika kao što su frekvencija, intenzitet i trajanje.[2].

Upravo u tu kategoriju spada i digitalna obrada govora, jer se njome zvučni signal transformiše u digitalni oblik, te se dalje obrađuje pomoću algoritama i matematičkih modela ili kao što je primjena tehnika poput spektrogramske analize, Fourierove transformacije, LPC metoda i sl.

Sve više se javlja potreba za raznovrsnom digitalnom obradom govora i koliko su brojna područja u kojima se primjenjuju postupci digitalne obrade govora. Neka od tih područja su sljedeća: fonetika, forenzička akustika i fonetika, telekomunikacije, multimedijski sustavi, digitalna televizija i radio, informacijske i obavještajne službe te naposljetku i logopedija [1].

Digitalna obrada se sama po sebi primarno sastoji iz tri koraka [6]:

- A/D konverzije – konverzije analognih signala u digitalni oblik,
- obrade tog digitalnog oblika,
- konverzije obrađenog digitalnog signala u analogni oblik.

## 2.2. *Govor kao analogni signal i A/D konverzija*

Govor se u svojoj prirodnoj formi javlja kao analogni signal, jer predstavlja kontinuirane promjene zvučnog pritiska u vremenu. Takav signal nije ograničen na diskretne vrijednosti, već sadrži beskonačan broj amplitudnih stanja, što je osnovna karakteristika analognih signala. Za njihovu obradu u digitalnim uređajima, prvenstveno je potrebno pretvoriti u digitalni oblik, odonso pretvoriti ih u niz brojeva koji imaju konačnu preciznost. Ova procedura se naziva analogno – digitalna (A/D) konverzija, a odgovarajući uređaj koji to izvršava se naziva A/D konverter (pretvarač).

Konceptualno, A/D konverziju posmatramo kao proces u tri koraka [6]:

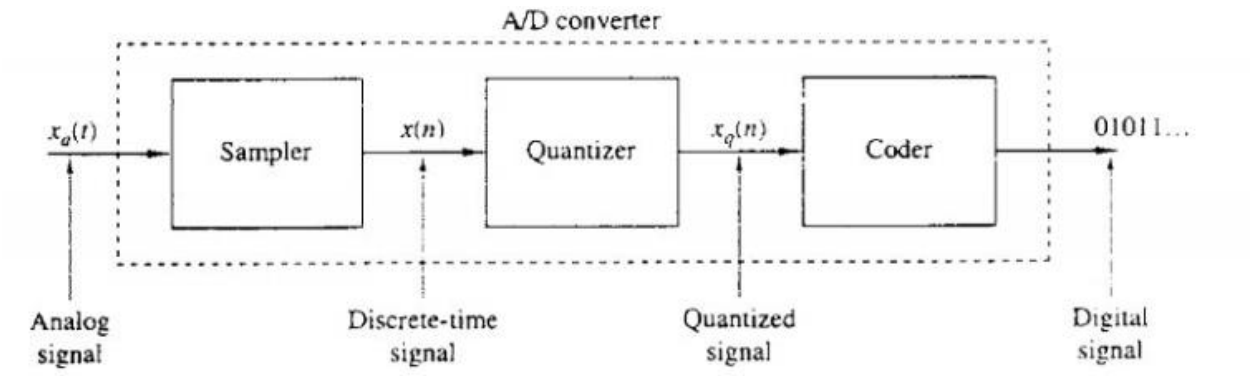


Slika 1. Osnovni elementi A/D konvertera

1. *Uzorkovanje*. Ovo je konverzija signala kontinualnog u vremenu u signal diskretan u vremenu, koji nastaje uzimanjem "uzoraka" tog signala u vremenski diskretnim trenucima. Dakle, ako je $x_a(t)$ ulaz za uzorkivač, izlaz je $x_a(nT) = x(n)$, gdje se $T$ naziva interval uzorkovanja. Dakle vrši se diskretizacija po vremenu.

2. *Kvantizacija*. Ovo je konverzija signala kontinulnih vrijednosti u diskretnim vremenskim trenucima, u signal diskretne vrijednosti (digitalni) u diskretnim vremenskim trenucima. Uzorci se zaokužuju na najbliži diskretni nivo, odnosno vrši se diskretizacija po amplitudi.

3. *Kodiranje*. U procesu kodiranja, svaka diskretna vrijednost je predstavljena binarnom sekvencom.

Važno je naglasiti da jedan binarni broj predstavlja samo jednu kvantizovanu vrijednost analognog signala u određenom vremenskom trenutku. Na primjer, ako A/D konverter koristi 8 bita, svaka izmjerena vrijednost se kodira u obliku binarne sekvence poput 01011000. Ova sekvenca odnosi se isključivo na jedan uzorak. Međutim, digitalni signal u cjelini ne čini samo jedan binarni broj, već niz takvih binarnih vrijednosti koje nastaju uzastopnim uzorkovanjem signala kroz vrijeme.

## *2.3. Nyquistov teorem*

Osnovna karakteristika procesa kvantizacije jest pojava greške, odnosno prisustva šuma u signalu u kontekstu akustike. Utjecaj šuma kvantizacije ovisi o rezoluciji, to jest o veličini koraka kvantizacije. Međutim, postoji nešto što omogućuje smanjenje broja šumova odnosno gubitka kvalitetete u zapisu. Teorem uzorkovanja ili Nyquistov teorem pokazuje kako se kontinuirani analogni signal može pretvoriti u slijed vremenski diskretnih impulsa i obrnuto, tako da nema nikakvog gubitka informacija, ukoliko je ostvareno sljedeće: frekvencija uzorkovanja kojom se uzimaju uzorci mora biti najmanje dva puta veća od najviše frekvencije $F_{max}$ koja se može pojaviti u analognom signalu koji se uzorkuje. Ovaj teorem dobio je ime po američkom fizičaru i inženjeru elektrotehnike i računarstva švedskog podrijetla Harryju Nyquistu (1889 – 1976) koji je svoj najveći doprinos dao u području telekomunikacija [1].

Matematički zapisano: $F_s \geq 2F_{max}$.

Dakle, u analognom kontinuiranom signalu ne smije biti viših frekvencija nego što je polovica frekvencije uzorkovanja, kako bi sama pretvorba iz kontinuiranog signala u niz diskretnih impulsa bila ostvariva bez ikakvog gubitka informacija.

Odnos između frekvencije uzorkovanja i kvalitete zvuka prikazano je u tabeli ispod [1]:

Tabela 6. Frekvencija uzorkovanja i kvaliteta zvuka

| **Frekvencija uzorkovanja** | **Gornja frekvencija audio signala** | **Napomena** |
|---|---|---|
| 8.000 Hz | 4.000 Hz | Telefonski prijenos |
| 32.000 Hz | 16.000 Hz | Cijelo govorno područje |
| 44.000 Hz | 22.000 Hz | Cijelo čujno područje |
| 96.000 Hz | 45.500 Hz | Profesionalna upotreba |

Dakle, telefon koristi frekvenciju uzorkovanja od oko 8.000 Hz, čime može obuhvatiti zvučne komponente do 4.000 Hz. Ovaj opseg je dovoljan za osnovni telefonski prijenos, odnosno razumijevanje govora, ali gubi većinu prirodnih nijansi glasa. 32.000 Hz omogućava prenos do 16.000 Hz, što pokriva cijelo govorno područje i sve relevantne akustičke informacije potrebne za kvalitetnu analizu govora, uključujući većinu formantskih frekvencija (diktafoni, digitalni snimači glasa I sl.). 44.100 Hz, što je standardna frekvencija audio CD-a i mnogih pametnih telefona (uključujući iPhone), omogućava obradu zvuka do 22.000 Hz, čime se obuhvata cijelo čujno područje ljudskog sluha (20–20.000 Hz). U to spadaju i WAV fajlovi te se nad njima mogu izvršavati određene analize u pojedinim softverskim alatima . 96.000 Hz koristi se u profesionalnoj upotrebi, npr. u muzičkoj produkciji, snimanju instrumenata i studijskim okruženjima, gdje je potrebna visoka preciznost i fleksibilnost u daljoj obradi.

## *2.4. Obrada digitalnog oblika signala, frekvencije i formanti*

Govorni signal u digitalnom obliku može se obrađivati na različite načine, u zavisnosti od cilja analize. Neki od najčešće korištenih postupaka uključuju: spektrogramsku analizu, formantsku analizu, LPC (Linear Predictive Coding), analizu temeljne frekvencije (F0), kao i analizu jittera i shimmera za dijagnostičke svrhe. U ovom radu fokus će biti stavljen na spektrogramsku analizu, budući da ona omogućava vizualizaciju promjena u frekvenciji, intenzitetu i vremenu što je naročito korisno pri poređenju različitih vokalnih modaliteta. Da bi spektrogram bio ispravno interpretiran, ključno je razumjeti osnovne karakteristike govornog signala, a to su frekvencije i formanti.

Frekvencija je fizikalna veličina kojom se izražava koliko se puta ponovio neki periodički događaj u određenom vremenskom intervalu. Mjerna jedinica je Hertz (Hz). Naziv je dobila po njemačkom fizičaru Heinrichu Rudolphu Hertzu (1857 – 1894). Ljudsko uho čuje zvukove u frekvencijskom rasponu od 16 do 20 000 Hz. Općenito, zvukove možemo podijeliti u šumove i tonove. Šum nastaje nepravilnim titranjem zvučnog izvora pri čemu se neprestano mijenjaju i frekvencija i amplituda te ispunjava cijelo jedno frekvencijsko područje Ton nastaje pravilnim, periodičnim titanjem zvučnog izvora i frekvencija je stalna . Ton je zapravo jednostavno sinusoidno titranje. Zvukove visoke frekvencije doživljavamo kao ,,svjetlije" i više, a zvukove niskih frekvencija doživljavamo kao ,,tamnije" i dublje [1].

Ako bi u ovu priču uključili i formante koji predstavljaju ključ u analizi ovog rada, prvenstveno ih možemo definisati na sljedeći način.

Baldwin i French (1990) opisuju formante kao vibracije na višim frekvencijama, koje su uzrokovane „trljanjima“ zračne struje o površinu vokalnih organa i rezonancijama pojedinih dijelova govornoga trakta [2].

Jednostavnije rečeno, formanti predstavljaju frekvencijske pojaseve pojačanog intenziteta u govornom signalu, koji nastaju zato što se određene frekvencije pojačavaju kada zvuk prolazi kroz usnu i nosnu šupljinu.

Svaki samoglasnik i mnogi suglasnici imaju svoj jedinstveni raspored formanata, pri čemu su najvažniji prvi (F1) i drugi formant (F2) jer omogućavaju razlikovanje između različitih glasova. Formanti su ključni u fonetskoj analizi jer nose informacije o artikulaciji, visini jezika, otvaranju vilice i poziciji jezika, čime omogućavaju automatsko ili vizuelno prepoznavanje glasova [7].

Prema Harrisonu (2013) tri najčešće korištene metode u mjerenju formantskih frekvencija jesu [2]:

- frekvencijski spektar,
- spektrogrami te
- LPC metoda.

Frekvencijski spektar prikazuje koje frekvencije postoje u signalu u određenom trenutku, ali ne prikazuje kako se mijenjaju kroz vrijeme. Spektrogram prikazuje kako se frekvencije primjenjuju kroz vrijeme. LPC je metoda koja prikazuje gdje se nalaze formanti tako što matematički modelira kako zvuk prolazi kroz govorni trakt.

U ovom radu, fokusirati ćemo se na spektrogramsku analizu koja se pored korištenja za mjerenje formantskih frekvencija koristi i za vizualno praćenje drugih akustičkih karakteristika govora kao što su šumovi, trajanje glasova, energetske promjene i sl., ali kroz vrijeme.

## *2.5. Fourijerova transformacija i spektrogram*

Kako bi se postigla analiza frekvencijskih komponenti signala, najosnovnija metoda u tu svrhu je Fourijerova transformacija. Fourijerova transformacija je matematički alat koji omogućuje analizu signala u frekvencijskom domenu. Ideja je da se svaki vremenski signal može prikazati kao zbroj sinusoida različitih frekvencija, amplituda i faza.

Ako imamo kontinuirani signal , njegova Fourierova transformacija definira se kao [8]:

$$X(\omega) = \int_{-\infty}^{+\infty} x(t)e^{-j\omega t}dt$$

Fourijerova transformacija je posebno korisna kada radimo sa stacionarnim signalima čije se statističke karakteristike ne mijenjaju kroz vrijeme (signal koji izgleda isto ko vrijeme). Ali, ako bi posmatrali govor koji nije stacionaran, onda je potrebno implementirati nešto drugo.

U stvarnom digitalnom svijetu radimo s diskretnim (uzorkovanim) podacima, a ne s kontinuiranim signalima. Fourijerova transformacija u svom izvornom obliku ne može se direktno primijeniti na takve podatke. Zato je uvedena diskretna Fourijerova transformacija (DFT). DFT je alat koji omogućuje da i diskretne vremenske signale analiziramo u frekvencijskom domenu. Za niz od N uzoraka, DFT se definira kao [9]:

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j\frac{2\pi}{N}kn}, \qquad k = 0,1 \dots, N-1$$

Međutim, implementacija DFTa zahtjeva veliki broj elementarnih operacija (množenja i sabiranja) koje je potrebno izvršiti, te se iz tog razloga koristi brza Fourijerova transformacija (FFT). FFT je brzi algoritam za rješavanje DFTa izražen slj. relacijom [9]:

$$X(m) = \sum_{k=0}^{\frac{N}{2}-1} x(2k){W_N}^{m2k} + \sum_{k=0}^{\frac{N}{2}-1} x(2k+1){W_N}^{m(2k+1)},$$

$$za\ x(2k), k = 0,1 \dots, \frac{N}{2} - 1\ i\ za\ x(2k+1), k = 0,1 \dots, \frac{N}{2} - 1$$

Na primjer, ako imamo govorni signal koji traje 2 sekunde i uzorkovan je frekvencijom od 16 kHz, FFT nam omogućava da prikažemo sve frekvencije koje taj signal sadrži (npr. osnovni ton glasa, šum, harmonike), ali bez informacije o tome kada se te frekvencije pojavljuju u vremenu.

Pošto je govorni signal nestacionaran i njegov frekvencijski sadržaj se mijenja kroz vrijeme (npr. prelaz sa suglasnika na samoglasnik), potrebna je transformacija koja podržava vremenske promjene, a to je kratkovremenska Furijerova transformacija (STFT). Ona dijeli signal na male vremenske segmente („prozore“) i na svaki segment primjenjuje FFT, te se na taj način dobija vremensko – frekvencijska reprezentacija.[9].

Na primjer, STFT može pokazati da se zvuk „m“ u riječi mačka javlja u prvoj desetinki sekunde i sadrži niže frekvencije, dok zvuk „a“ ima izraženije formante i višu energiju srednjeg spektra.

Ako bismo uporedili FFT i STFT, možemo zamisliti da imamo snimak u kojem osoba prvo šuti, zatim naglo izgovori “ah!”, pa opet šuti. Koristeći FFT, dobili bismo da taj signal sadrži određeni spektar frekvencija, ali ne bismo znali kada su se te frekvencije pojavile, jer se cijeli signal

posmatra kao jedna cjelina. STFT je metoda koja kombinuje vremensku i frekvencijsku analizu tako što primjenjuje FFT na male segmente signala. Svaki segment je vremenski isječak signala (npr. 0.1 sekundi), na koji se dodatno primjenjuje prozorska funkcija. Nakon što se na prvi segment primijeni FFT, prozor se pomjera unaprijed i isti postupak se ponavlja na sljedećem segmentu. Na taj način dobijamo niz vremenski FFT analiza koje zajedno formiraju pregled kako se frekvencijski sadržaj mijenja kroz vrijeme. Ova vizuelna reprezentacija promjene frekvencija u signalu naziva se spektrogram.

## *2.6. D/A konverzija*

Nakon digitalne obrade signala (kao što je spektrogramska analiza), može se javiti potreba da se digitalni signal ponovo predstavi u analognom obliku. Taj proces naziva se digitalno-analogna konverzija (D/A konverzija). U hardverskom smislu, za to služi D/A konverter (DAC), koji pretvara diskretne digitalne vrijednosti u kontinuirani napon (analogni signal).

Prvi korak u D/A konverziji je da se te digitalne vrijednosti "zadržavaju" tokom određenog perioda, dok ne stigne sljedeća. Taj proces naziva se nulti red zadržavanja (engl. Zero Order Hold, ZOH). To je metod rekonstrukcije signala u kojem se vrijednost svakog diskretnog uzorka zadržava konstantno dok ne stigne naredni uzorak. Drugim riječima, za svaki uzorak, DAC generiše naponski nivo i drži ga nepromijenjenim sve do naredne vrijednosti. Rezultat ovakvog procesa je stepeničasti signal – oblik analogne izlazne funkcije koji se sastoji od „stepenica“, pri čemu svaka stepenica odgovara jednoj vrijednosti uzorka. Zbog naglih promjena između stepenica, ZOH signal sadrži visoke frekvencijske komponente koje nisu bile prisutne u originalnom signalu. Da bi se to ublažilo, nakon DAC-a se često koristi niskopropusni filtar koji eliminiše te visoke frekvencije, te na izlazu dobijamo glatki analogni signal [8].

Bitno je naglasiti da je DAC hardverski uređaj koji fizički pretvara digitalne vrijednosti u naponske signale koji se zatim šalju na zvučnik. Zvučnik te napone koristi da pomjera membranu koja stvara zvučne talase u zraku, a samim time i zvuk koji čujemo.

S druge strane, ukoliko želimo prikazati digitalni signal u analognom obliku u softverskom okruženju, bez korištenja fizičkog DAC-a, to je moguće izvršiti kroz simulaciju. U tom slučaju, koristi se interpolacija, kojom se između diskretnih tačaka generiše glatka kriva koja približno odgovara analognom signalu. Ova metoda omogućava da se u MATLAB-u ili sličnim alatima vizualizuje kako bi signal izgledao nakon D/A konverzije. Neke od često korišćenih interpolacionih metoda uključuju: linearnu interpolaciju, kubnu, kvadratnu, te sinc interpolaciju.

Takođe, moderni DAC uređaji često sadrže ugrađene digitalne interpolacione filtre, koji obavljaju oversampling (povećanje brzine uzorkovanja) i smanjuju potrebu za strmim analognim filterima.

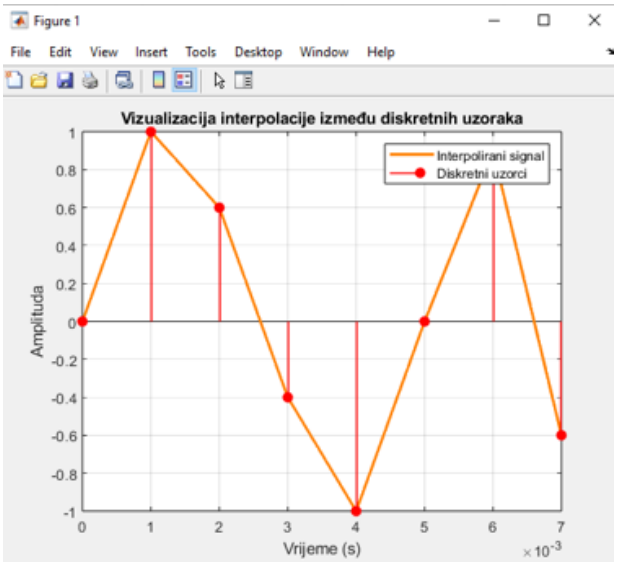


Slika 2. Vizualizacija linearne interpolacije između diskretnih uzoraka u MATLABu

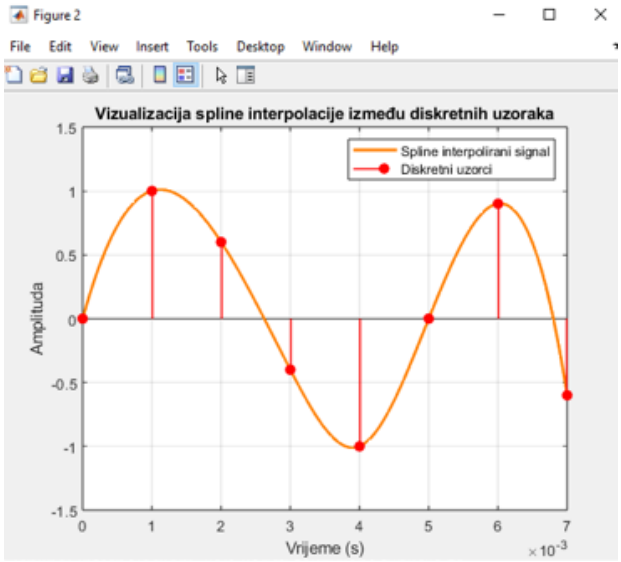


Slika 3. Vizualizacija kubne interpolacije između diskretnih uzoraka u MATLABu

Kod korišten za izradu prethodnih vizualizacija, nalazi se u **Prilogu A.**

# 3. PREGLED I ANALIZA ALATA

Tabela 7. Pregled alata koji se koriste u analizi govora

| Alat | Tip alata | Prednosti | Nedostaci | Izvor |
|---|---|---|---|---|
| Praat | Softverski alat za akustičku analizu govora | Besplatan, intuitivan za korištenje. Omogućava vizualizaciju signala (spektrogram) i poređenje modaliteta | Ne uključuje napredne algoritme i grafičke metode. Nema naprednih transformacija i sl. | [1], [3], [4], [5] |
| AVQI skripta | Praat dodatak, skripta za dijagnostičku procjenu glasa | Specijalizovana za automatsku evaluaciju kvalitete glasa. Često se koristi u logopediji i kliničkom okruženju | Fokusirana je na određene parametre, ne omogućava vizualno poređenje modaliteta | [1] |
| MATLAB | Softverski alat za vizualizaciju i digitalnu obradu signala | Bogat skup funkcija za obradu signala, FFT, LPC, vizualizaciju i automatizaciju | Skupe licence, kompleksnost za početnike, zahtjeva jake performanse | [2] |
| JASP | Softver za statističku obradu rezultata | Pruža vizualan prikaz statistike, pogodan za analizu formantskih vrijednosti | Ne omogućava prikaz spektrograma. Koristi se isključivo za obradu numeričkih rezultata | [2] |
| CSL (Computerized Speech Lab) | Profesionalni kombinovani softver i hardver za akustičku analizu | Koristi se u kliničke i istraživačke svrhe za dijagnostiku slaga, te pruža standardizovane rezultate | Ne omogućava modifikacije softvera, ne mogu se dodavati vlastiti algoritmi) | [3], [4] |
| TF32 | Softver za akustičku analizu govora | Dizajniran za mjerenje vokala i samoglasnika, koristan u fonetici | Ograničen broj funkcija, vrlo zastarjeo | [3] |
| WaveSurfer | Softver za vizualizaciju i slušanje govora | Lagan softver, može prikazati spektrogram i koristiti se za brzu obradu i pregled signala | Spektrogramska analiza nije dovoljno detaljna u usporedbi s nekim alatima iznad | [3] |

Na osnovu analize alata prikazanih u tabeli, može se zaključiti da svaki od njih ima specifične prednosti i nedostatke. Praat je besplatan i jednostavan za upotrebu, te omogućava vizualizaciju spektrograma i poređenje modaliteta, zbog čega je posebno popularan u logopedskoj praksi. Zajedno s AVQI skriptom, nudi automatsku evaluaciju kvalitete glasa i koristi se u kliničkim okruženjima. JASP pruža jednostavan statistički prikaz rezultata, ali ne omogućava obradu samog signala. S druge strane, CSL, TF32 i WaveSurfer nude funkcionalnosti za rad s vokalima i signalima, ali imaju ograničenu fleksibilnost, zastarjele interfejse ili manju preciznost u poređenju s drugim rješenjima.

Za potrebe ovog rada – koji podrazumijeva detaljnu spektrogramsku analizu frekvencijskih karakteristika govora, najbolji alati bili bi Praat, CSL i MATLAB. Ipak, zbog potrebe za naprednom kontrolom parametara, ručnim podešavanjem spektrograma i vizualizacijom rezultata na visokom nivou, odlučeno je da se koristi MATLAB.

Iako je MATLAB korišten samo u jednom od analiziranih radova [2], njegova moć u obradi signala, automatizaciji i fleksibilnosti jasno ga pozicionira kao najbolji izbor za ovakav zadatak. U kontekstu ove teme, on omogućava ne samo detaljnu spektrogramsku analizu, već i implementaciju vlastitih algoritama i eksperimentisanje s različitim filtrima što će se primijeniti u nastavku.

# 4. DIGITALIZACIJA GOVORNOG SIGNALA I PRAKTIČNA PRIMJENA SPEKTROGRAMSKE ANALIZE GOVORA

Govorni signal je u svom prirodnom obliku analogan, što znači da predstavlja neprekidnu promjenu zvučnog pritiska kroz vrijeme. Da bi se mogao obraditi u digitalnom okruženju, mora se pretvoriti u diskretni (digitalni) signal putem procesa poznatog kao analogno-digitalna konverzija (ADC).

Kao konkretan primjer signala, uzet je vlastiti glas, snimljen tri puta, prvo normalnim tonom, nakon toga šapatom, a zatim višim tonom. Sva tri primjera su snimljena mobilnim uređajem (iPhone), uz pomoć aplikacije Voice Memos i s trajanjem 9 sekundi.

U govornim zapisima je izgovorena rečenica: "Ja sam Jusuf Dacić i ovo je testni govor za moj projektni rad iz predmeta digitalna obrada signala."

Zvučni signal koji je proizveden prvo ide na mikrofon, ugrađen u mobitelu, koji ga pretvara u električni analogni signal tako što mehaničke vibracije (zvuk) pretvori u električne promjene napona. Tu signal prvi put postaje električan nakon čega ide na A/D konverter koji obavlja tri glavne radnje:

- uzorkovanje – uzima uzorke signala u jednakim vremenskim intervalima.
- kvantizacija – uzorcima se pridružuju vrijednosti najbližih kvantizacijskih nivoa

Rezultat je niz brojeva koji predstavlja signal u diskretnom vremenu. Ovaj niz se čuva u formatu kao što je m4a.

Proces uzorkovanja se može opisati kao [10]:

$$[n] = x_a(nT)$$

gdje je:

$x[n]$ – diskretni signal,

$x_a(t)$ – originalni analogni signal,

$T = \frac{1}{fs}$ – period uzorkovanja,

$fs$ = frekvencija uzorkovanja (tipično 44100 Hz kod mobilnih uređaja u jednoj sekundi).

Pošto su sva tri govorna zapisa koja su snimljena trajanja od 9 sekundi, na osnovu toga možemo izračunati broj uzoraka [10]:

$$N = fs \times t = 44100 \times 9 = 396900$$

Dakle govorni signali koji će biti predstavljen u softverskom okruženju sadrže 396900 uzoraka.

Nakon uzorkovanja, signal još uvijek sadrži kontinualne vrijednosti koje nije moguće direktno obraditi još. Zbog toga se primjenjuje kvantizacija – proces kojim se svaka vrijednost uzorka zaokružuje na najbliži diskretni nivo.

Broj kvantizacijskih nivoa zavisi od broja bitova koji se koriste za predstavljanje svakog uzorka i računa se kao [10]:

$$L = 2^n = 2^{16} = 65536$$

$L$ – broj kvantizacionih nivoa

$n$ – broj bita po uzorku (aplikacija Voice Memos obično snima u 16 – bitnoj kvantizaciji, te je ovo također standard za WAV i M4A audio snimke).

Također, važno je spomenuti da je kodiranje, tj. pretvaranje kvantiziranih vrijednosti u binarni zapis, već urađeno automatski u pozadini tokom snimanja preko aplikacije. Na kraju tog procesa dobijen je .m4a file, koji već sadrži sve podatke spremljene u digitalnom obliku.

## *4.1. Analiza govora izgovorenog normalnim tonom*

U ovom poglavlju će signal (govor s normalnim tonom) biti predstavljen u MATLAB softverskom okruženju. Dakle, snimak je automatski sačuvan u M4A formatu i prebačen na računar. Budući da MATLAB ne podržava direktno M4A format, fajl je konvertovan u WAV pomoću online alata cloudconvert.com. Nakon toga, audio zapis je postavljen u isti fajl gdje se nalazila MATLAB skripta, kako bi funkcija `audioread()` mogla ispravno da ga učita.

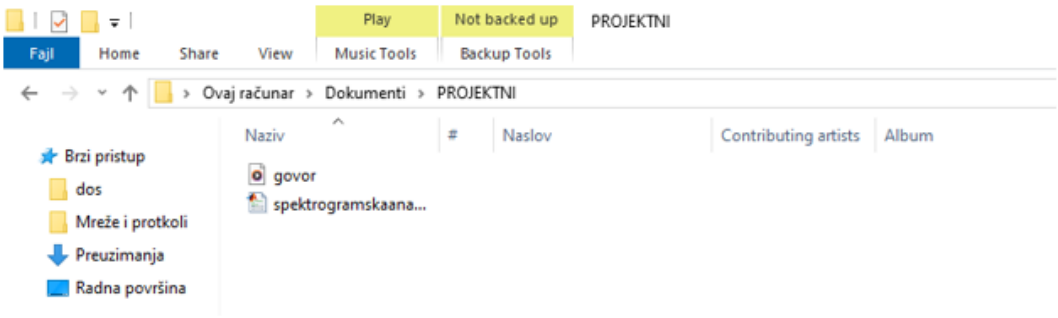


Slika 4. Organizacija fajla u MATLAB okruženju

Nakon pokretanja MATLAB koda, dobit ćemo vremenski prikaz digitalnog signala.

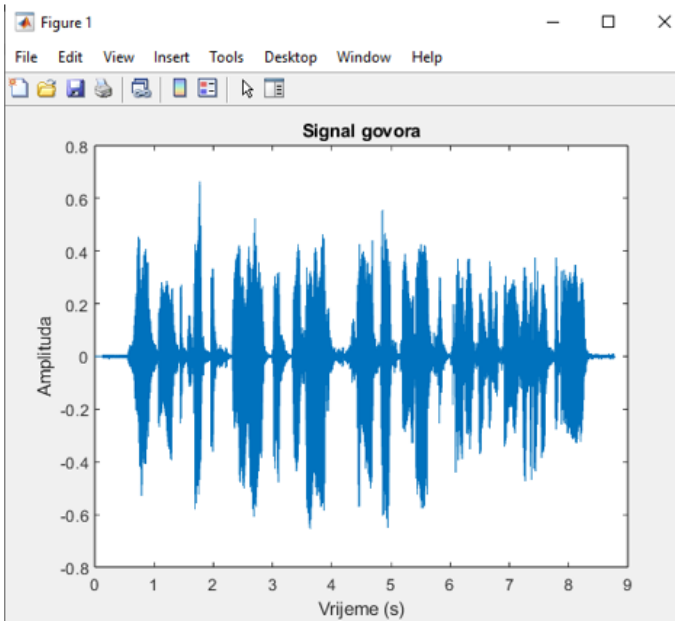


Slika 5. Vremenski prikaz govora izgovorenog normalnim tonom

Kod korišten za izradu vizualizaciju prikazane na slici, nalazi se u **Prilogu B**

Na slici iznad, prikazan je vremenski zapis govora (u digitalnom obliku). Horizontalna osa označava vrijeme trajanja govora u sekundama, dok vertikalna osa prikazuje promjenu amplitude audio signala. Ovakav prikaz omogućava uvid u trenutke kada su izgovoreni snažniji zvučni segmenti (kao što su samoglasnici ili naglašene riječi), te pauze i tiši dijelovi govora.

Na početku signala, jasno se uočava porast amplitude, što odgovara izgovoru riječi *„Ja sam Jusuf“*, te u nastavku, signal postaje gušći i ravnomjerniji, što je posljedica kontinuiteta govora tokom izgovora duže rečenice bez prekida.

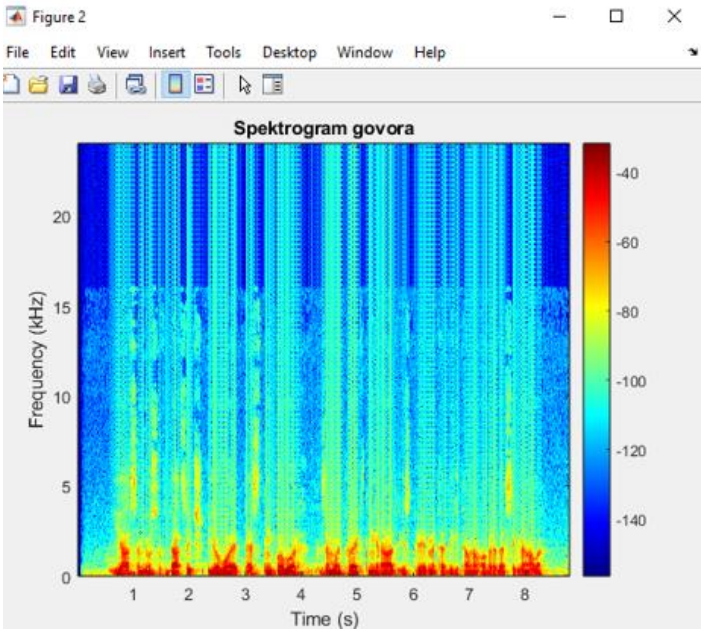


Slika 6. Spektrogramski prikaz govora izgovorenog normalnim tonom

Kod korišten za izradu vizualizaciju prikazane na slici nalazi se u **Prilogu B**

Horizontalna osa predstavlja vrijeme trajanja izgovorene rečenice, dok vertikalna osa prikazuje frekvenciju u kHz. Boje u spektrogramu prikazuju intenzitet signala na određenim frekvencijama kroz vrijeme. Ta jačina signala u određenom trenutku je iskazana u dB (decibelima).

Crvena i žuta boja označavaju jači intenzitet (naglašene riječi i samoglasnici), dok svijetloplava i tamnoplava predstavljaju tihe dijelove govora ili pauze (npr. suglasnici). Intenzitet je najveći u donjem dijelu spektra (0–3 kHz), što odgovara formantima. Gornji dijelovi spektra odgovaraju većoj količini šuma, suglasnicima tipa „š“, „s“, te se obično prikazuju tamnijim nijansama.

F1 formanti koji su na području od 300 Hz do 900 Hz, na samom dnu grafa, prikazani kao kontinuirana crvena boja, F2 formanti su između 1 kHz do 2.5 kHz, ali sa manjim prekidima iste boje. F3 formanti su iznad 3 kHz, ali su slabije izraženi zbog prirode signala i prisustva visokofrekventnog šuma.

Bitno je naglasiti da boje ne idu ispod nule jer nula označava maksimalni intenzitet, te je iz tog razloga najjača boja (crvena) obično pri dnu slike.

Posmatrajući spektrogram s lijeva na desno, može se primijetiti kako se kroz vrijeme smjenjuju periodi intenzivnijeg i tišeg govora. Prvi izraženiji crveni segment u donjem dijelu grafa (oko 0.5 s) odgovara riječi „Ja“, dok odmah zatim dolazi riječ „sam“. U intervalu oko 1.5 do 2.5 sekunde pojavljuju se gušći i jači dijelovi, što ukazuje na izgovor riječi „Jusuf Dacić“. Ovi dijelovi sadrže veći broj formanata i više energije jer uključuju glasovne segmente s više tonaliteta (npr. samoglasnici: „u“, „a“, „i“).

U sredini i pri kraju spektrograma govorni tok postaje kontinuiran, sa čestim smjenama intenziteta što odgovara ostatku rečenice.

Prethodni signal također može biti i filtriran u svrhu otklanjanja visokofrekventnog šuma radi boljeg i ljepšeg prikaza signala i naglašavanja ključnih karakteristika. Filtriranje je izvšeno pomoću niskopropusnog digitalnog Butterworth filtra sa graničnom frekvencijom od 3500 Hz. Kod dizajna digitalnog filtra koristi se tzv. "red filtra", koji određuje koliko naglo filtar odvaja frekvencije koje želimo zadržati (korisne) od onih koje želimo ukloniti (nepoželjne ili potisnute). Što je red filtra veći, prelaz između tih frekvencija je "strmiji", odnosno oštriji, te samim time filtar brže „presječe“ spektar. U ovom radu korišten je šesti red filtra (order = 6), što znači da je odvajanje korisnih od potisnutih frekvencija vrlo precizno, a opet dovoljno računarski efikasno. Kao rezultat, potisnute frekvencije će biti one iznad 3500 Hz, koje uglavnom sadrže šum i manje važne dijelove govora.

Pri filtriranju je korištena MATLAB funkcija `filtfilt()`, koja vrši tzv. dvostruko filtriranje, prvo signal filtrira unaprijed (kao da ide naprijed kroz vrijeme), a zatim ga filtrira unazad (kao da ide unazad kroz vrijeme). Ova metoda služi za uklanjanje faznog pomaka, što je neželjeni efekat kod običnog filtriranja gdje se dijelovi signala mogu pomjeriti u vremenu (ne nalaze se više tačno na svom mjestu). To može narušiti izgled i struktura signala. Dvostruko filtriranje poništava taj pomak, pa se sačuva prirodni oblik signala nakon čega rezultat izgleda kao originalni govor, ali bez šuma.

Na sljedećoj slici prikazan je filtrirani signal govora u vremenskom domenu. Vizualno, njegov oblik je veoma sličan originalnom signalu, međutim, ključna razlika će biti prikazana na spektrogramu, također u nastavku.

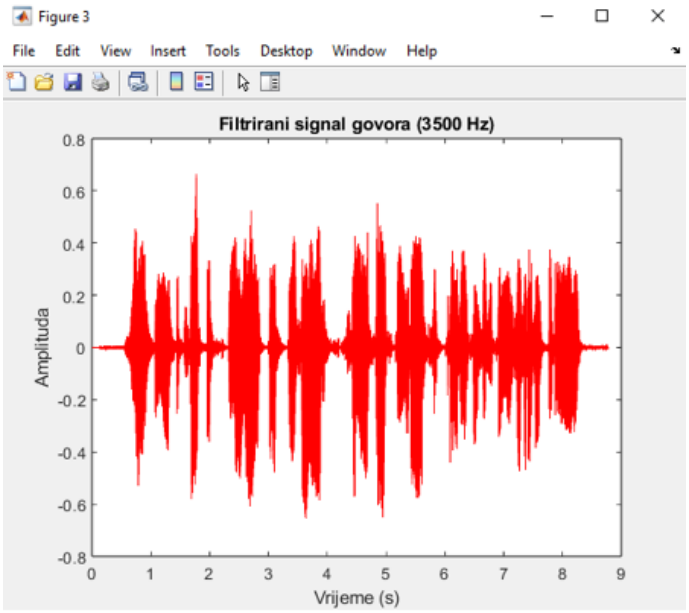


Slika 7. Vremenski prikaz govora izgovorenog normalnim tonom nakon filtriranja

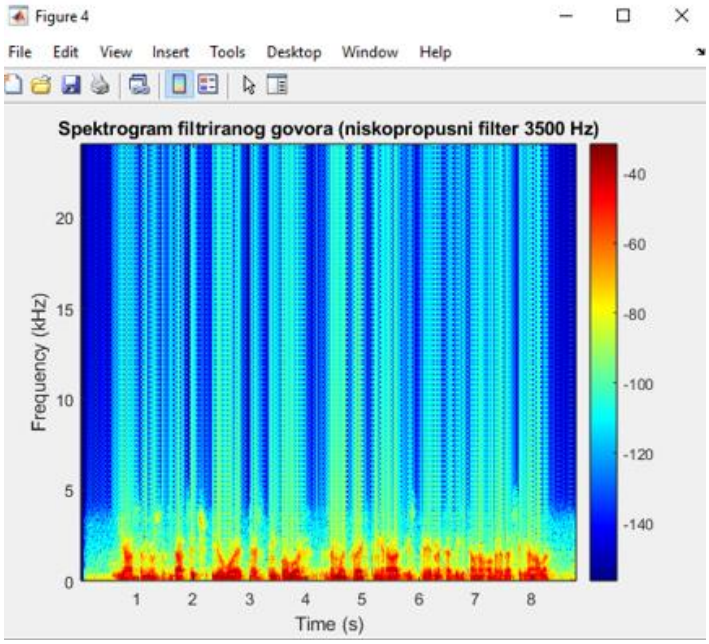


Slika 8. Spektrogramski prikaz govora izgovorenog normalnim tonom nakon filtriranja

Kod korišten za izradu vizualizacija prikazanih prethodno, nalazi se u **Prilogu C**.

U poređenju s originalnim spektrogramom, vidi se da su komponente iznad 3500 Hz oslabljene ili potpuno uklonjene. Formanti su jasno ostali vidljivi, te je time sačuvana bitna govorna informacija, a eliminisane su smetnje koje nisu važne za razumijevanje izgovorenog sadržaja. Svijetloplave linije u gornjoj polovini spektrograma predstavljaju određene šumove koji nisu u potpunosti uklonjeni.

## *4.2. Analiza govora izgovorenog šapatom*

U ovom dijelu rada analiziran je signal iste rečenice: *"Ja sam Jusuf Dacić i ovo je testni govor za moj projektni rad iz predmeta digitalna obrada signala"*, ali izgovorene šapatom. Cilj ove analize je uporediti akustičke karakteristike šapata s normalnim govorom, te uočiti razlike u vremenskoj i frekvencijskoj domeni, kao i nakon filtriranja.

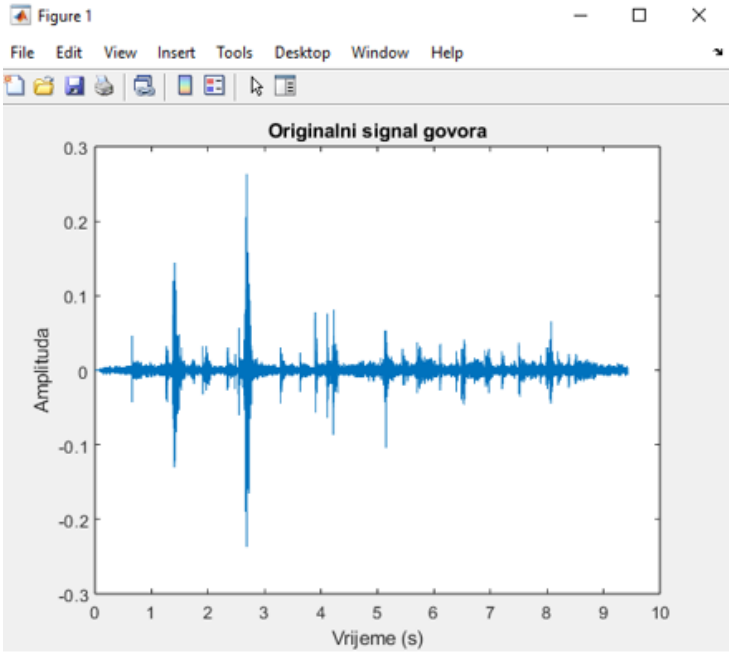


Slika 9. Vremenski prikaz govora izgovorenog šapatom

Vizuelno, signal se značajno razlikuje od govora izgovorenog normalnim tonom. Amplitude su znatno manje. To je očekivano, jer šapat ne uključuje vibraciju glasnih žica, već se proizvodi samo

strujanjem zraka kroz usnu šupljinu. Dakle, ovaj signal djeluje "tiši" i "rjeđi" u amplitudnom smislu, s manje izraženim skokovima.

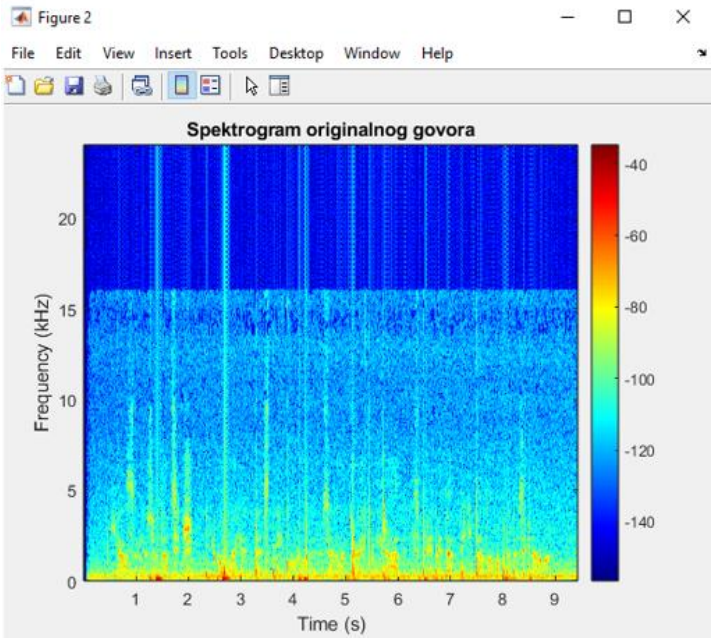


Slika 10. Spektrogramski prikaz govora izgovorenog šapatom

Primjećujemo da spektrogram šapatnog govora prikazuje jasno vidljive razlike u frekvencijskom sadržaju naspram spektrograma govora normalnog tona. Većina intenziteta se nalazi u donjem dijelu spektra (ispod 3–4 kHz), ali su ukupni intenziteti znatno niži u poređenju s normalnim govorom. Formanti su prisutni, ali slabije izraženi. Također, crvena boja gotovo potpuno izostaje, a najintenzivnije komponente su prikazane žutom bojom.

Ova razlika ukazuje na to da šapat sadrži znatno manje energije u svim frekvencijskim opsezima, te da ne aktivira jake rezonantne pojave u vokalnom traktu kao što je to slučaj kod glasnog govora.

Nakon što je signal šaptanog govora prošao kroz isti filter, rezultat je signal s još ublaženijom amplitudom prikazan na slici ispod, ali bez značajnih gubitaka u govornoj strukturi.

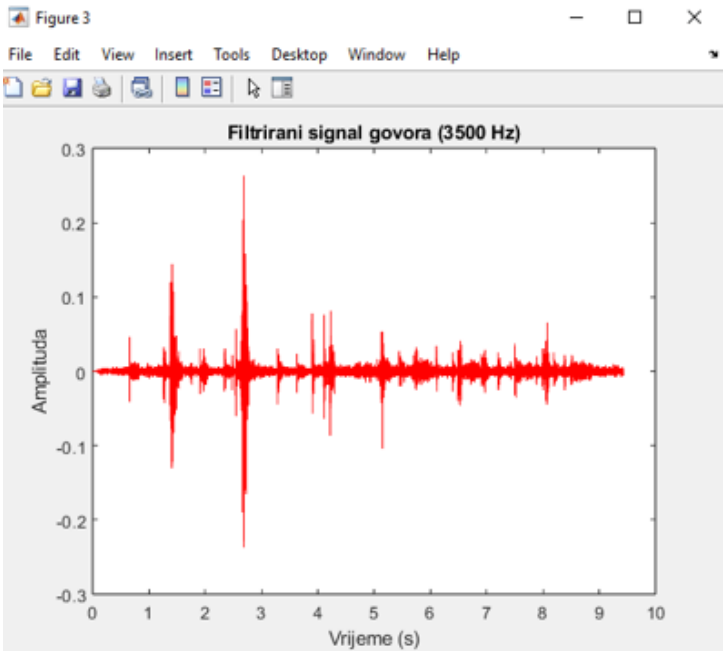


Slika 11. Vremenski prikaz govora izgovorenog šapatom nakon filtriranja

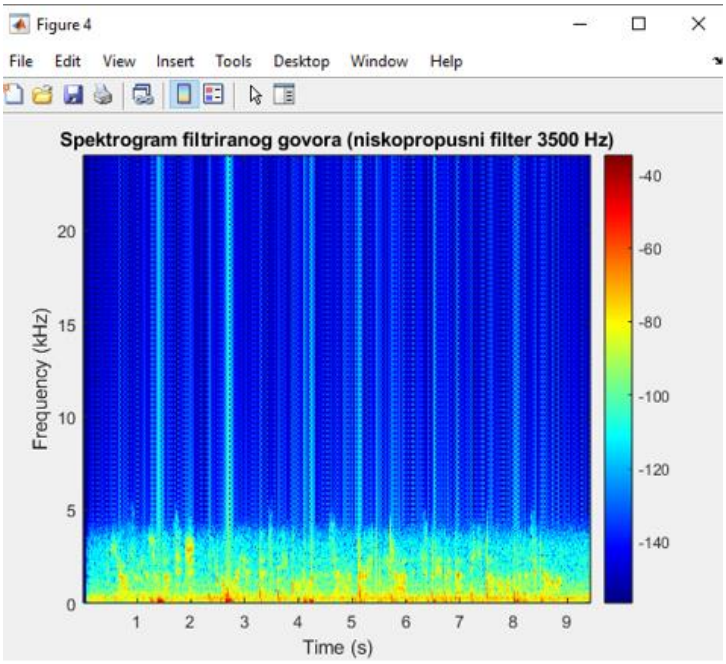


Slika 12. Spektrogramski prikaz govora izgovorenog šapatom nakon filtrianja

## 4.3. *Analiza govora izgovorenog visokim tonom*

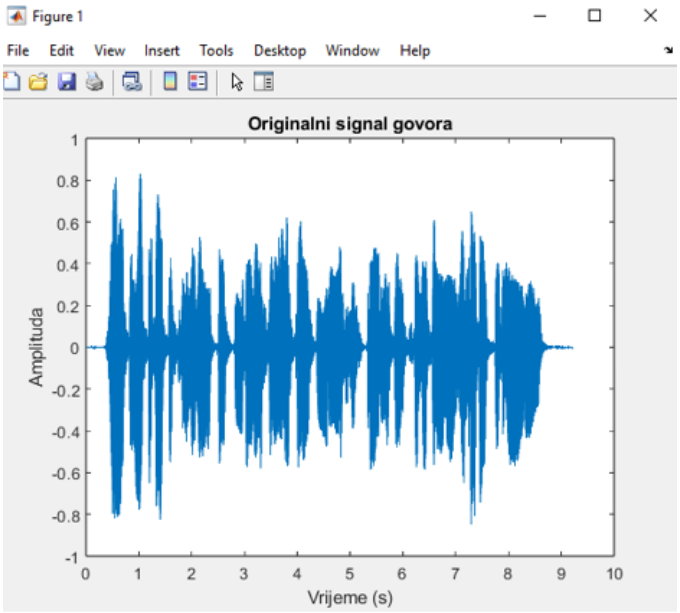


Slika 13. Vremenski prikaz govora izgovorenog visokim tonom

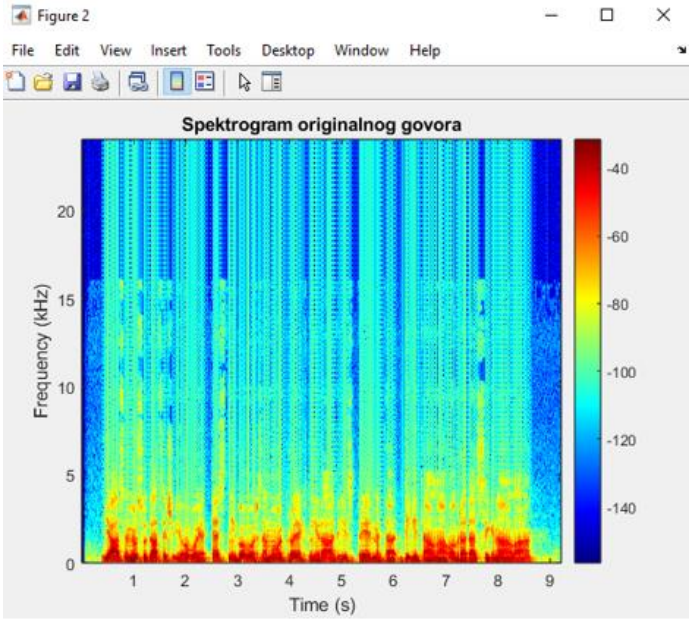


Slika 14. Spektrogramski prikaz govora izgovorenog visokim tonom

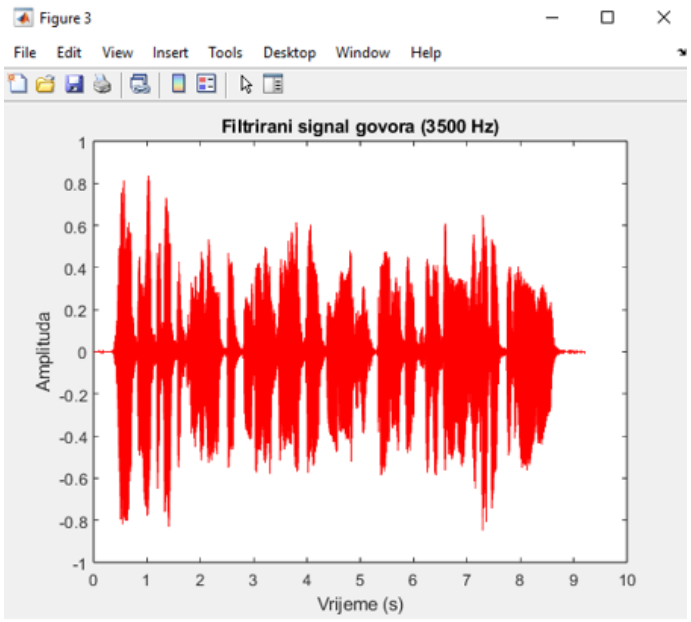


Slika 15. Vremenski prikaz govora izgovorenog visokim tonom nakon filtriranja

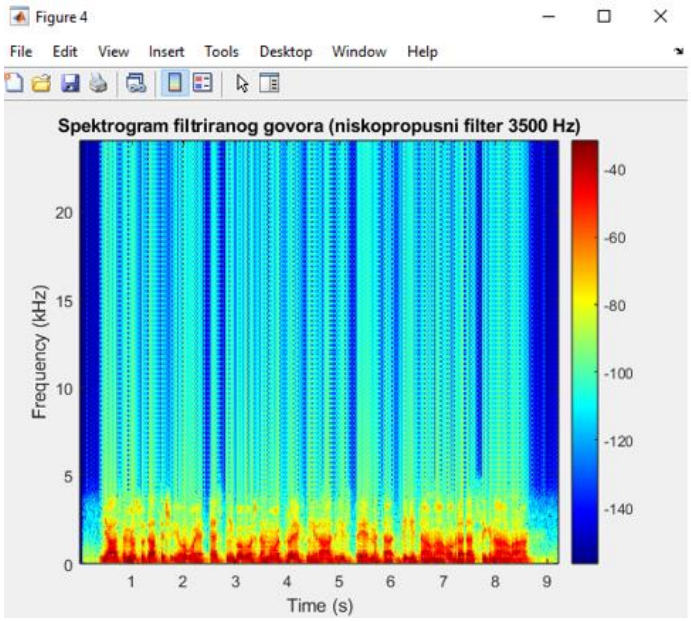


Slika 16. Spektrogramski prikaz govora izgovorenog visokim tonom nakon filtriranja

U poređenju s normalnim govorom, ovaj signal na vremenskom prikazu ima znatno veće amplitude, koje ukazuju na jači intenzitet zvuka. Spektrogram jasno prikazuje razlike, također. Crvene i narandžaste boje u većoj količini dominiraju u donjem dijelu spektra. Prisustvo snažnih komponenti i u višim frekvencijama (iznad 4–5 kHz) ukazuje da govor sadrži dodatnu energiju šuma. Nakon filtracije primjećujemo da su frekvencije iznad 3500 Hz značajno oslabljene kao što je bio slučaj u prethodnim primjerima.

### *4.4. Analiza kombinovanog govora: šapat i povišen ton u jednoj rečenici*

U ovom dijelu analiziran je govor u kojem je prva polovina rečenice izgovorena šapatom, a druga polovina povišenim tonom.

Svrha ove analize je da se na jednom zajedničkom spektrogramu jasno uoče razlike u zvučnim karakteristikama, posebno kroz kontrast u intenzitetu boja, gdje šapat rezultira slabijim, tamnijim prikazom, dok glasniji govor proizvodi svjetlije, izraženije zone.

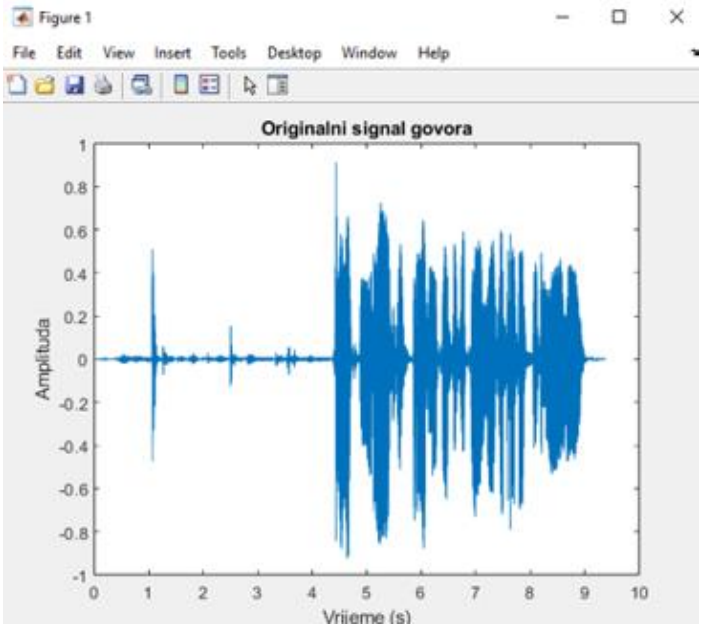


Slika 17. Vremenski prikaz kombinovanog govora

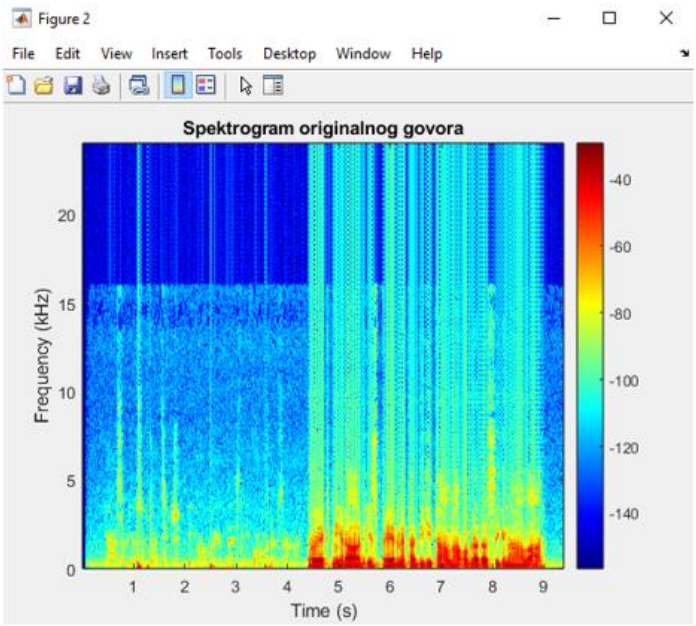


Slika 18. Spektrogramski prikaz kombinovanog govora

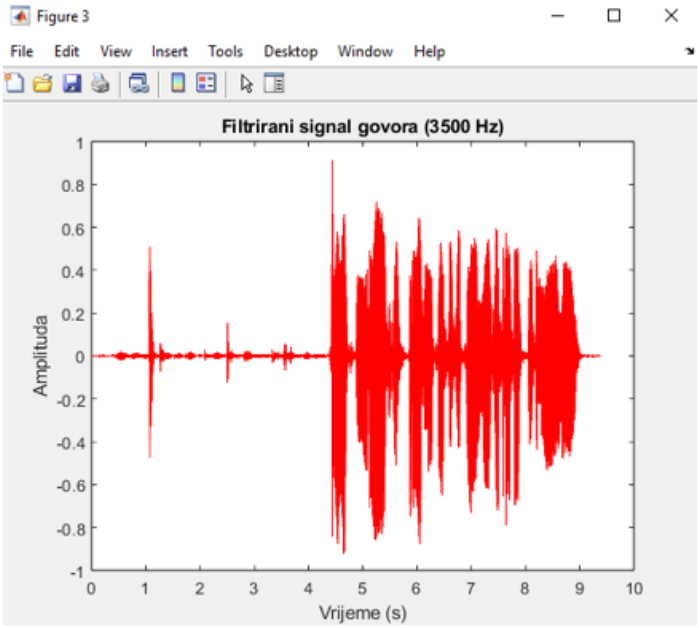


Slika 19. Vremenski prikaz kombinovanog govora nakon filtriranja

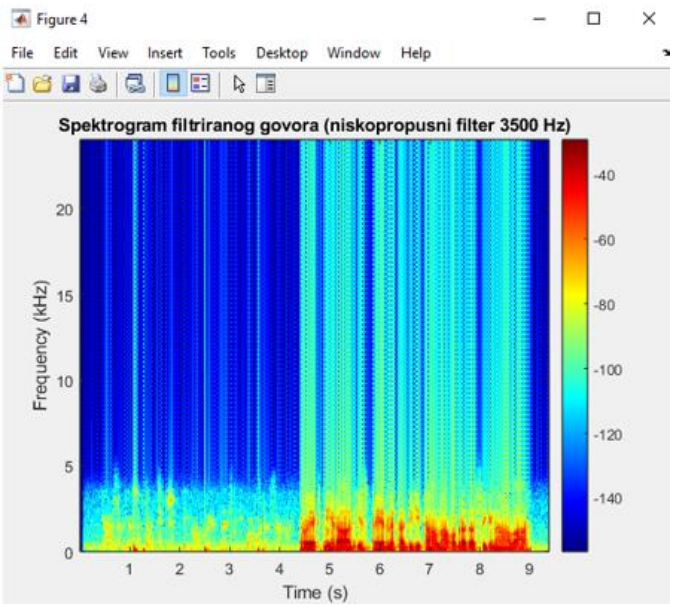


Slika 20. Spektrogramski prikaz kombinovanog govora nakon filtriranja

## *4.5. Analiza spektrograma iste rečenice izgovorena brzo i sporo normalnim tonom, nakon filtriranja.*

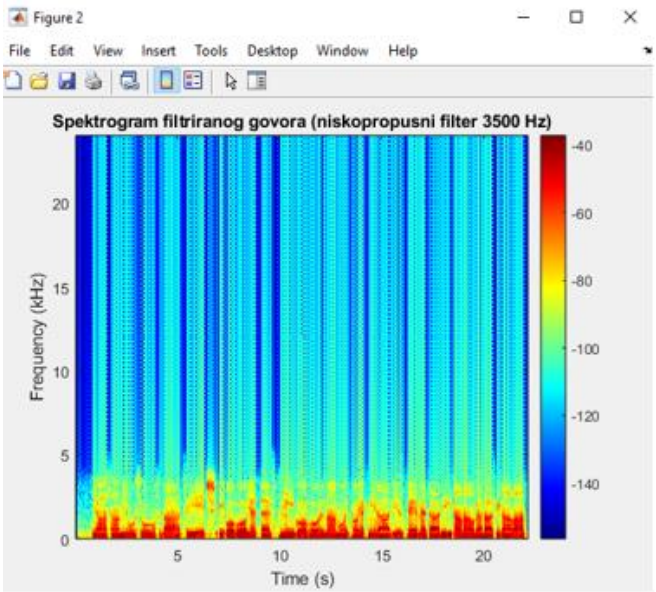


Slika 21. Spektrogramski prikaz iste rečenice izgovorene brzo

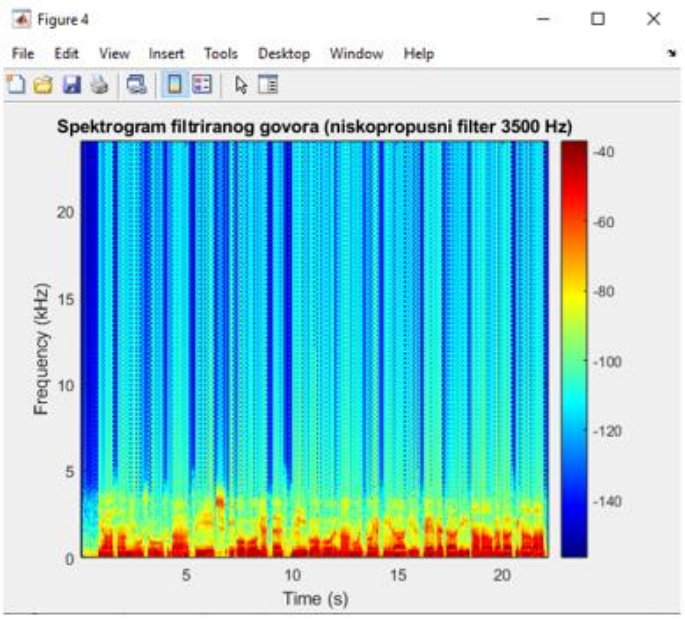


Slika 22. Spektrogramski prikaz iste rečenice izgovorene sporo

Primjećujemo da spektar frekvencija I energetska distribucija (posebno u donjem dijelu ispod 3.5 kHz) ostaju približno isti jer se izgovara ista rečenica istim tonom (samo drugačijim tempom).

## *4.6. Rekonstrukcija digitalnog signala u analogni oblik*

Digitalni signal koji je prethodno dobijen snimanjem i uzorkovanjem govora pokušat ćemo rekonstruisati u približan analogni oblik korištenjem linearne interpolacije u MATLAB koju smo spomenuli u teorijskom dijelu rada. Iako se ne koristi fizički digitalno-analogni konverter, ovaj pristup omogućit će nam matematičku simulaciju procesa rekonstrukcije.

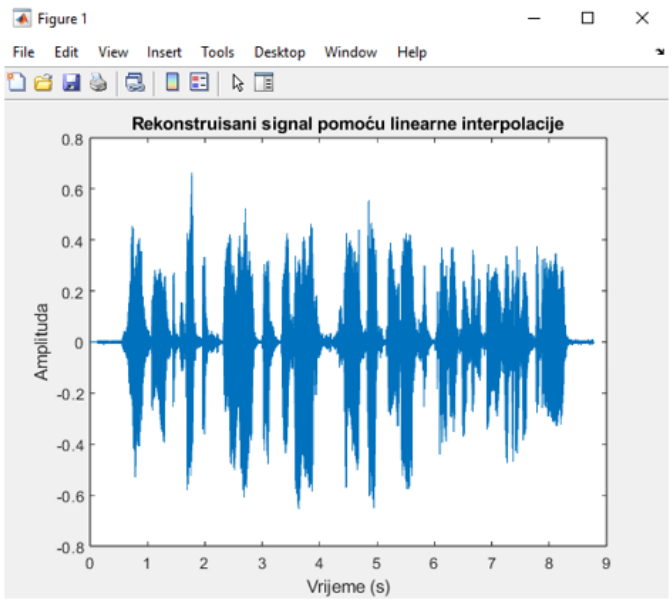


Slika 23. Rekonstruisani signal pomoću linearne interpolacije

Primjećujemo da signal veoma liči na početni digitalni signal, jer je original imao veliki broj uzoraka (frekvencija uzorkovanja je bila 44.100 Hz na mobitelu), pa je oblik već bio vrlo precizan, jer što je veća frekvencija uzorkovanja, digitalni signal je bliži svom originalu. Linearna interpolacija samo popunjava prostor između uzoraka, ali kod ovako guste serije tačaka promjena nije drastična.

# 5. PRIMJENA DIGITALNE OBRADE GOVORA DANAS

Digitalna obrada govora danas ima ključnu ulogu u savremenom društvu i prisutna je u gotovo svakom aspektu svakodnevne komunikacije, tehnologije i medicine. Ova oblast omogućila je razvoj brojnih sistema koji zavise od precizne analize, prepoznavanja i sinteze govora, a bez nje bi mnoge današnje tehnologije bile gotovo nezamislive.

Jedna od najrasprostranjenijih primjena digitalne obrade govora jeste u glasovnom prepoznavanju, koje koriste asistenti poput Siri, Google Assistant i Amazon Alexa. Ovi sistemi analiziraju govorni signal korisnika u realnom vremenu, primjenjujući algoritme za prepoznavanje uzoraka, fonetsku transkripciju i semantičku obradu. Osnovna komponenta takvih sistema je upravo digitalno obrađen signal, koji omogućava da računari interpretiraju značenje izgovorenih riječi i odgovaraju u skladu s kontekstom [11].

U oblasti telekomunikacija, digitalna obrada govora omogućava tri ključna procesa: kodiranje, kompresiju i prenos glasa. U tom kontekstu, kodeci (od *coder-decoder*) poput GSM (Global System for Mobile Communications) i G.729 imaju ključnu ulogu. To su specijalizovani softverski ili hardverski algoritmi koji [8]:

1. Kodiraju govor: pretvaraju analogni glas u digitalni signal,
2. Kompresuju signal: smanjuju veličine audio podataka govora bez značajnog gubitka razumljivosti i kvaliteta, kako bi se podaci efikasnije prenosili putem mreža,
3. Dekodiraju govor: na prijemnoj strani rekonstruiraju govor iz kompresovanog digitalnog formata nazad u analogni signal.

Ovi kodeci su zasnovani na naprednim digitalnim algoritmima.

Takođe, u medicinskoj fonetici i logopediji, digitalna obrada govora omogućava tačnu analizu govora pacijenata, dijagnostiku glasovnih poremećaja i praćenje terapije. Softveri kao što su Praat, CSL i AVQI se koriste za detekciju promjena u govoru koje ukazuju na bolesti grla, neurološke poremećaje, ili oporavak nakon hirurških intervencija [12].

U sferi sigurnosti, obrada govora se koristi za identifikaciju putem glasa, gdje se analiziraju jedinstvene karakteristike nečijeg glasa. Ovakvi sistemi se koriste u bankarstvu, vojsci i pristupnim sistemima kao metoda autentifikacije korisnika.

Posebnu ulogu igra u obrazovanju i inkluziji, gdje se koriste aplikacije za automatsku transkripciju predavanja, pretvaranje govora u tekst (za gluhe i nagluhe), i tehnologije asistivnog tipa koje omogućavaju osobama s govornim poteškoćama da komuniciraju.

Bez digitalne obrade govora, današnji svijet bi bio tehnički mnogo siromašniji. Ne bi bilo moguće implementirati inteligentne asistente, govor bi se morao prenositi analognim putem uz visoke šumove i smanjenu pouzdanost, a medicinska dijagnostika i asistivne tehnologije bi bile znatno ograničene. Govorna komunikacija s računarima bila bi nemoguća, a pristup informacijama za mnoge grupe korisnika bi bio znatno otežan.

Samim time što bi se govor prenosio u analognom obliku (kao neprekidan električni signal kroz žice), bio bi veoma osjetljiv na šumove i smetnje, posebno na velikim udaljenostima. Svaki put kada bi se pojačao, snimio ili dalje proslijedio, gubio bi na kvaliteti jer se greške nakupljaju. Osim toga, analogni signal je teško kompresovati jer ima beskonačno mnogo vrijednosti između dvije tačke pa je vrlo teško pronaći dijelove signala koje bi kompresioni algoritam mogao iskoristiti. Teško ga je i zaštititi (ne može se lako šifrovati), i nije ga moguće precizno rekonstruisati.

Digitalna obrada je sve to promijenila – jer je govor sada pretvoren u podatke. A kada je u obliku podataka, možemo ga sažeti (kompresovati) jer ima ograničen broj vrijednosti i jer se sastoji od niza brojeva. Moguće je i šifrovanje radi sigurnosti, i ponovni prikaz baš onako kako je izvorno snimljen.

# ZAKLJUČAK

Digitalna obrada govora danas čini srž mnogih tehnologija koje svakodnevno koristimo, često i ne razmišljajući o njihovoj složenosti, od mobilne i internet telefonije, preko glasovnih asistenata u pametnim uređajima, pa sve do sofisticiranih sistema za prepoznavanje i sintezu govora. Kroz ovaj rad prikazano je kako se analogni govor može uspješno pretvoriti u digitalni oblik, detaljno analizirati i na kraju rekonstruisati, korištenjem softverskih metoda. Spektrogramska analiza se pokazala kao izuzetno korisna u vizualizaciji promjena unutar govora, identifikaciji formanata i poređenju različitih modaliteta izgovora.

Analiza dostupnih alata pokazala je da MATLAB pruža visok nivo preciznosti i potpunu kontrolu nad parametrima uz pomoć programiranja. Predstavlja jedan od glavnih alata u svrhu naučnih istraživanja ovog polja jer omogućava temeljitu i pouzdanu analizu frekvencijskih karakteristika govora u različitim tonovima.

Bez digitalne obrade, govor bi se morao prenositi isključivo u analognom obliku, što bi uzrokovalo veću podložnost smetnjama, šumu i gubitku kvaliteta. Digitalna obrada ne samo da omogućava efikasnu i kvalitetnu komunikaciju, već otvara prostor za napredne metode analize koje su danas ključne u brojnim naučnim, medicinskim i tehničkim oblastima.

# LITERATURA


[1] Kristina Spajić, 'Primjena PRAAT programa u logopediji', Sveučilište u Zagrebu: ERF, 2019.

[2] I. Bašić, Akustička analiza općeprihvaćenoga hrvatskoga i srpskog govora – formantska analiza i mjere fundamentalne frekvencije, Doktorski rad, 2018.

[3] J. &. H. R. A. Hillenbrand, "Formant analysis of speech," *Optimizing Vowel Formant Measurements in Four Acoustic Analysis Systems for Diverse Speaker Groups,* 2003.

[4] M. S. Y. &. W. T. Ali, "Comparison of Praat and Computerized Speech Lab for Formant Analysis in Maxillectomy Patients," *Frontiers in Neuroscience,* 2023.

[5] J. C. E. A. &. B. P. A. Cavalcanti, "Acoustic Analysis of Vowel Formant Frequencies in Genetically-Related and Non-Genetically Related Speakers," *PLoS ONE,* 2021.

[6] A. Hasković, "Digitalna obrada signala (prezentacija)," 2023.

[7] P. priručnik, Formant analysis of speech, rad3.

[8] A. V. &. S. R. W. Oppenheim, Discrete-Time Signal Processing, Upper Saddle River: Prentice Hall, 2010.

[9] Princeton.edu, Spectrogram and FFT.

[10] J. G. M. D. G. Proakis, Digital Signal Processing: Principles, Algorithms and Applications, Upper Saddle River, 2006.

[11] L. R. &. S. R. W. Rabiner, Introduction to Digital Speech Processing. Foundations and Trends in Signal Processing, 2010.

[12] D. L. M. Horga, Fonetika: Uvod u govornu komunikaciju i fonetsku analizu, Zagreb: Ibis grafika., 2016.

## POPIS SLIKA

**Slika 1.** Osnovni elementi A/D konvertera ..... 6
**Slika 2.** Vizualizacija linearne interpolacije između diskretnih uzoraka u MATLABu ..... 12
**Slika 3.** Vizualizacija kubne interpolacije između diskretnih uzoraka u MATLABu ..... 12
**Slika 4.** Organizacija fajla u MATLAB okruženju ..... 17
**Slika 5.** Vremenski prikaz govora izgovorenog normalnim tonom ..... 17
**Slika 6.** Spektrogramski prikaz govora izgovorenog normalnim tonom ..... 18
**Slika 7.** Vremenski prikaz govora izgovorenog normalnim tonom nakon filtriranja ..... 20
**Slika 8.** Spektrogramski prikaz govora izgovorenog normalnim tonom nakon filtriranja ..... 20
**Slika 9.** Vremenski prikaz govora izgovorenog šapatom ..... 21
**Slika 10.** Spektrogramski prikaz govora izgovorenog šapatom ..... 22
**Slika 11.** Vremenski prikaz govora izgovorenog šapatom nakon filtriranja ..... 23
**Slika 12.** Spektrogramski prikaz govora izgovorenog šapatom nakon filtrianja ..... 23
**Slika 13.** Vremenski prikaz govora izgovorenog visokim tonom ..... 24
**Slika 14.** Spektrogramski prikaz govora izgovorenog visokim tonom ..... 24
**Slika 15.** Vremenski prikaz govora izgovorenog visokim tonom nakon filtriranja ..... 25
**Slika 16.** Spektrogramski prikaz govora izgovorenog visokim tonom nakon filtriranja ..... 25
**Slika 17.** Vremenski prikaz kombinovanog govora ..... 26
**Slika 18.** Spektrogramski prikaz kombinovanog govora ..... 27
**Slika 19.** Vremenski prikaz kombinovanog govora nakon filtriranja ..... 27
**Slika 20.** Spektrogramski prikaz kombinovanog govora nakon filtriranja ..... 28
**Slika 21.** Spektrogramski prikaz iste rečenice izgovorene brzo ..... 28
**Slika 22.** Spektrogramski prikaz iste rečenice izgovorene sporo ..... 29
**Slika 23.** Rekonstruisani signal pomoću linearne interpolacije ..... 30
**Slika 24.** MATLAB kod za linearnu i kubnu interpolaciju ..... 37
**Slika 25.** MATLAB kod za spektrogramsku analizu ..... 39
**Slika 26.** MATLAB kod za niskopropusni Butterworth filtar ..... 41

## POPIS TABELA

**Tabela 1.** Kratak pregeld rada pod nazivom “Primjena PRAAT programa u logopediji” .....3
**Tabela 2.** Kratak pregeld rada pod nazivom “Primjena formantske analize u konstrastivnoj akustici hrvatskog i srpskog jezika”.....3
**Tabela 3.** Kratak pregled rada pod nazivom “Optimizing Vowel Formant Measurements in Four Acoustic Analysis Systems for Diverse Speaker Groups”.....4
**Tabela 4.** Kratak pregled rada pod nazivom “Comparison of Praat and Computerized Speech Lab for Formant Analysis in Maxillectomy Patient”.....4
**Tabela 5.** Kratak pregled rada pod nazivom “Acoustic Analysis of Vowel Formant Frequencies in Genetically-Related and Non-Genetically Related Speakers” .....4
**Tabela 6.** Frekvencija uzorkovanja i kvaliteta zvuka.....7
**Tabela 7.** Pregled alata koji se koriste u analizi govora.....13
**Tabela 8.** Ključne komande za linearnu i kubnu interpolaciju .....38
**Tabela 9.** Ključne komande za spektrogramsku analizu .....40
**Tabela 10.** Ključne komande za niskopropusni Butterworth filtar .....41

# PRILOG A

```
% Diskretni uzorci signala
n = 0:7;
x = [0 1 0.6 -0.4 -1 0 0.9 -0.6];  % uzorci
fs = 1000;                         % frekvencija uzorkovanja
t = n / fs;                        % vrijeme uzoraka

% Gusto vrijeme za interpolaciju
t_interp = linspace(t(1), t(end), 500);

% LINEARNA interpolacija
x_linear = interp1(t, x, t_interp, 'linear');

% SPLINE (kubna) interpolacija
x_spline = interp1(t, x, t_interp, 'spline');

% Vizualizacija linearne interpolacije
figure;
plot(t_interp, x_linear, 'Color', [1 0.5 0], 'LineWidth', 2); hold on;
stem(t, x, 'r', 'filled', 'LineWidth', 1.2);
title('Vizualizacija interpolacije između diskretnih uzoraka');
xlabel('Vrijeme (s)');
ylabel('Amplituda');
legend('Interpolirani signal', 'Diskretni uzorci');
grid on;

% Vizualizacija spline interpolacije
figure;
plot(t_interp, x_spline, 'Color', [1 0.5 0], 'LineWidth', 2); hold on;
stem(t, x, 'r', 'filled', 'LineWidth', 1.2);
title('Vizualizacija spline interpolacije između diskretnih uzoraka');
xlabel('Vrijeme (s)');
ylabel('Amplituda');
legend('Spline interpolirani signal', 'Diskretni uzorci');
grid on;
```

Slika 24. MATLAB kod za linearnu i kubnu interpolaciju

Tabela 8. Ključne komande za linearnu i kubnu interpolaciju

| Linija/funkcija | Opis |
|---|---|
| t_interp = linspace(t(1), t(end), 500); | Generiše gusto raspoređene tačke vremena između prvog i posljednjeg uzorka. Koristi se za vizualizaciju glađih (interpoliranih) linija. |
| x_linear = interp1(t, x, t_interp, 'linear'); | Vršena je linearna interpolacija između poznatih uzoraka. Funkcija interp1 povezuje tačke pravim linijama i generiše nove vrijednosti na t_interp. |
| x_spline = interp1(t, x, t_interp, 'spline'); | Vršena je kubna (spline) interpolacija između poznatih tačaka. Ova metoda koristi trećestepene polinome kako bi glatko spojila tačke i dala zaobljeniji signal. |
| plot(...), stem(...) | Kombinovani prikaz interpoliranog signala (plot) i diskretnih uzoraka (stem) u istom grafu. Omogućava vizualno poređenje između originalnog i interpoliranog signala. |
| legend(...) | Postavlja legende koje razlikuju interpolirane signale i diskretne uzorke u prikazu. |

# PRILOG B

```
% Učitavanje govora
[signal, fs] = audioread('govor.wav');

% Prikaz vremenskog signala
t = (0:length(signal)-1)/fs;
figure;
plot(t, signal);
xlabel('Vrijeme (s)');
ylabel('Amplituda');
title('Signal govora');

% Parametri spektrograma
window = hamming(512);
noverlap = 256;
nfft = 1024;

% Prikaz spektrograma
figure;
spectrogram(signal, window, noverlap, nfft, fs, 'yaxis');
title('Spektrogram govora');
colormap jet;
colorbar;
```

Slika 25. MATLAB kod za spektrogramsku analizu

Tabela 9. Ključne komande za spektrogramsku analizu

| Linija/funkcija | Opis |
|---|---|
| `audioread('govor.wav')` | Omogućava učitavanje zvučne datoteke iz radnog direktorija. U ovom slučaju, file govor.wav se učitava i pretvara u signal te varijablu fs, koja predstavlja frekvenciju uzorkovanja signala (definiše koliko uzoraka u sekundi je korišteno pri digitalizaciji zvuka — tipično 44100 Hz kod mobilnih uređaja. |
| `(0:length(signal)-1)/fs` | Generiše vektor vremena za prikaz signala. Ovaj vektor je potreban kako bi se signal mogao pravilno prikazati na horizontalnoj osi vremenskog grafa. |
| `plot(t, signal)` | Prikazuje signal u vremenskom domenu (amplituda kroz vrijeme). |
| `xlabel(), ylabel(), title()` | Postavljaju nazive osa i naslove grafova. |
| `hamming(512)` | Definiše Hammingov prozor dužine 512 uzoraka za analizu segmenta signala. |
| `noverlap = 256` | Definiše preklapanje između prozora (50% preklapanja). |
| `nfft = 1024` | Broj tačaka za izračunavanje Fourierove transformacije (frekvencijska rezolucija) |
| `spectrogram(...)` | Generiše spektrogram signala na osnovu definisanih parametara. |
| `colormap jet i colorbar` | Podešavaju boje prikaza i legendu za intenzitet (dB) |

# PRILOG C

```
% Niskopropusni Butterworth filter (granična frekvencija 3500 Hz)
fc = 3500;
[b, a] = butter(6, fc / (fs / 2), 'low');
signal_filtered = filtfilt(b, a, signal);
```

Slika 26. MATLAB kod za niskopropusni Butterworth filtar

Tabela 10. Ključne komande za niskopropusni Butterworth filtar

| Linija/funkcija | Opis |
|---|---|
| `fc = 3500;` | Postavlja graničnu frekvenciju niskopropusnog filtra na 3500 Hz – komponente iznad ove vrijednosti biti će oslabljene ili uklonjene. |
| `[b, a] = butter(6, fc / (fs / 2), 'low')` | Kreira koeficijente niskopropusnog Butterworth filtra šestog reda. Filtrira signale ispod 3500 Hz, uz normalizaciju prema Nyquistovoj frekvenciji (fs/2). |
| `signal_filtered = filtfilt(b, a, signal);` | Primjenjuje dvostruko filtriranje unaprijed i unazad, bez faznog pomaka – omogućava zadržavanje vremenske strukture signala. |